AIML homework 1

姓名: 王子川　　**学号:** PB25000055

1 平方损失的偏差-方差分解

(a) 偏差-方差分解的完整公式推导如下:

$$\begin{aligned}
\mathbb{E}_{S,\epsilon}[(y-Z)^2] &= \mathbb{E}_{S,\epsilon}[(f_*(\boldsymbol{x}_0)+\epsilon-Z)^2] \\
&= \mathbb{E}[\epsilon^2] + 2\mathbb{E}_{S,\epsilon}[(f_*(\boldsymbol{x}_0)-Z)\epsilon] + \mathbb{E}_S[(f_*(\boldsymbol{x}_0)-Z)^2] \\
&= \sigma^2 + 2\mathbb{E}_S[f_*(\boldsymbol{x}_0)-Z]\mathbb{E}[\epsilon] + \mathbb{E}_S[((m-f_*(\boldsymbol{x}_0))-(m-Z))^2] \\
&= \sigma^2 + (m-f_*(\boldsymbol{x}_0))^2 - 2\mathbb{E}_S[(m-f_*(\boldsymbol{x}_0))(m-Z)] + \mathbb{E}_S[(m-Z)^2] \\
&= \sigma^2 + (m-f_*(\boldsymbol{x}_0))^2 - 2(m-f_*(\boldsymbol{x}_0))\mathbb{E}_S[m-Z] + \mathrm{Var}_S(Z) \\
&= \sigma^2 + (m-f_*(\boldsymbol{x}_0))^2 + \mathrm{Var}_S(Z).
\end{aligned}$$

由于 Z 由训练集 S 决定, 且 ϵ 与 S 独立, 因此 ϵ 与 $f_*(\boldsymbol{x}_0)-Z$ 独立. 另外, $m-f_*(\boldsymbol{x}_0)$ 是常数, 可直接提出期望. 两个交叉项的期望均为零, 分别利用了

$$\mathbb{E}[\epsilon]=0,\ \mathbb{E}_S[m-Z]=0.$$

(b) 判断如下.

1. 错误. 模型的平均预测等于真实条件均值等价于 $m=f_*(\boldsymbol{x}_0)$, 此时期望测试误差为 $\sigma^2+\mathrm{Var}_S(Z)$, 不一定为零. 只有噪声方差和预测方差都为零时, 期望测试误差才为零.
2. 正确. 测试噪声不变时, 平方偏差的增加小于预测方差的减少, 因此两者之和减小, 期望测试误差下降.
3. 错误. 模型的训练误差越低说明模型在给定数据集上的拟合程度更好, 不能说明其泛化能力更强.

2 平方损失下的多输出回归

(a) 第 j 个输出的均方误差

$$L_j(\boldsymbol{w}_j)=\frac{1}{N}\sum_{i=1}^{N}(\boldsymbol{w}_j\cdot\phi(\boldsymbol{x}_i)-y_{ij})^2,$$

因此总平方损失为

$$L(\boldsymbol{W})=\sum_{j=1}^{n}L_j(\boldsymbol{w}_j).$$

只改变 $\boldsymbol{w}_k$ 并保持其他参数不变时, 只有 $L_k(\boldsymbol{w}_k)$ 可能变化, 因为其余损失项均不含参数 $\boldsymbol{w}_k$.

(b) 答案是肯定的. 对任意 $\boldsymbol{W}$, 每项损失均不小于对应单输出问题的最小值, 因此总损失不小于各最小值之和. 各单输出问题均存在最优解, 且参数可以独立选择, 所以组合这些最优解即可达到这个下界. 因此

$$\min_{\boldsymbol{W}}L(\boldsymbol{W})=\min_{\boldsymbol{W}}\sum_{j=1}^{n}L_j(\boldsymbol{w}_j)=\sum_{j=1}^{n}\min_{\boldsymbol{w}_j}L_j(\boldsymbol{w}_j).$$

反过来, 若联合最优解中的某一列不是对应单输出问题的最优解, 则只替换该列就能严格降低总损失, 与联合最优性矛盾. 因此两种求解方式等价. 这里利用的是损失可分解和参数可独立选择, 不需要假设不同输出在统计上独立.

(c) 此时不能直接组合两个单输出问题的最优解. 若两个单输出问题各自的最优解唯一且不同, 设为

$$\boldsymbol{w}_1^* = \arg\min_{\boldsymbol{w}_1} L_1(\boldsymbol{w}_1),\ \boldsymbol{w}_2^* = \arg\min_{\boldsymbol{w}_2} L_2(\boldsymbol{w}_2).$$

约束后的目标仍是最小二乘问题, 存在最优解. 设 $\boldsymbol{W}^* = [\boldsymbol{w}_0, \boldsymbol{w}_0]$ 为一个最优解, 即

$$\boldsymbol{W}^* \in \arg\min_{\boldsymbol{W}:\, \boldsymbol{w}_1 = \boldsymbol{w}_2} L(\boldsymbol{W}).$$

则约束后总损失的最小值不小于两个单输出问题的无约束最小值之和.

$$\min_{\boldsymbol{w}_1 = \boldsymbol{w}_2} L(\boldsymbol{W}) = \min_{\boldsymbol{w}_0} \big[L_1(\boldsymbol{w}_0) + L_2(\boldsymbol{w}_0)\big] \geq \min_{\boldsymbol{w}_1} L_1(\boldsymbol{w}_1) + \min_{\boldsymbol{w}_2} L_2(\boldsymbol{w}_2).$$

事实上, 不等号 $\geq$ 是严格的. 否则若取等, 两项损失必须同时达到各自的最小值, 由最优解的唯一性有

$$\boldsymbol{w}_1^* = \boldsymbol{w}_2^* = \boldsymbol{w}_0.$$

这与题设 $\boldsymbol{w}_1^* \neq \boldsymbol{w}_2^*$ 相矛盾.

因此约束后的最小损失满足

$$\min_{\boldsymbol{w}_1 = \boldsymbol{w}_2} L(\boldsymbol{W}) > \min_{\boldsymbol{w}_1} L_1(\boldsymbol{w}_1) + \min_{\boldsymbol{w}_2} L_2(\boldsymbol{w}_2).$$

这说明它们的损失不能同时达到各自无约束的最小值. 与 (b)中不同的是, (c)问的约束使得各列参数不能再独立选择.

3 线性回归: 特征表示, 模型训练与正则化

(a) 特征向量

$$\phi(\boldsymbol{x}) = [1, x_1, x_2]^\top.$$

设计矩阵 Φ 和目标向量 $\boldsymbol{y}$ 分别为

$$\Phi = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 1 \\ 1 & -1 & 0 \\ 1 & 0 & -1 \\ 1 & -1 & -1 \end{bmatrix} \in \mathbb{R}^{6\times 3},\ \boldsymbol{y} = \begin{bmatrix} 2 \\ 0 \\ 3 \\ -4 \\ -2 \\ -5 \end{bmatrix} \in \mathbb{R}^6.$$

考虑线性方程组

$$\Phi \boldsymbol{w} = \boldsymbol{y},$$

第 1,4 个样本对应的方程相加可得截距为 -1, 再代入第 1,2 个样本解出权重向量

$$\boldsymbol{w}_A = [-1, 3, 1]^\top.$$

代回验证得

$$\Phi \boldsymbol{w}_A = [2, 0, 3, -4, -2, -5]^\top = \boldsymbol{y},$$

因此全部六条样本均被精确拟合.

(b) 把目标函数写成矩阵形式

$$\begin{aligned} J_\lambda(\boldsymbol{w}) &= N^{-1}\|\Phi\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \lambda\|P\boldsymbol{w}\|_2^2 \\ &= N^{-1}(\Phi\boldsymbol{w} - \boldsymbol{y})^\top(\Phi\boldsymbol{w} - \boldsymbol{y}) + \lambda(P\boldsymbol{w})^\top(P\boldsymbol{w}) \\ &= \boldsymbol{w}^\top(N^{-1}\Phi^\top\Phi + \lambda P)\boldsymbol{w} - 2N^{-1}\boldsymbol{y}^\top\Phi\boldsymbol{w} + N^{-1}\boldsymbol{y}^\top\boldsymbol{y}. \end{aligned}$$

这里使用了 $P^\top P = P$. 上式是关于 $\boldsymbol{w}$ 的二次函数, 且二次项的系数矩阵对称, 因此对 $\boldsymbol{w}$ 求梯度得

$$\nabla_{\boldsymbol{w}} J_\lambda(\boldsymbol{w}) = 2(N^{-1}\Phi^\top\Phi + \lambda P)\boldsymbol{w} - 2N^{-1}\Phi^\top\boldsymbol{y}.$$

(c) 参数更新的迭代公式为

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta\nabla_{\boldsymbol{w}} J_\lambda(\boldsymbol{w}^{(t)}).$$

其中 t 为迭代次数, $\eta = \frac{1}{4}$ 为学习率.

残差 $\boldsymbol{r}^{(t)}$ 的计算公式为

$$\boldsymbol{r}^{(t)} = \boldsymbol{y} - \Phi\boldsymbol{w}^{(t)}.$$

在初始参数处, 梯度为

$$\nabla_{\boldsymbol{w}} J_{1/3}(\boldsymbol{w}^{(0)}) = -\frac{2}{N}\Phi^\top\boldsymbol{r}^{(0)} + \frac{2}{3}P\boldsymbol{w}^{(0)} = \left[2, -\frac{10}{3}, -\frac{14}{3}\right]^\top.$$

t	$\boldsymbol{w}^{(t)}$	$J_\lambda(\boldsymbol{w}^{(t)})$	$\boldsymbol{r}^{(t)}$
0	$[0,\ 1,\ -1]^\top$	$\frac{29}{3}$	$[1,\ 1,\ 3,\ -3,\ -3,\ -5]^\top$
1	$\left[-\frac{1}{2},\ \frac{11}{6},\ \frac{1}{6}\right]^\top$	$\frac{367}{108}$	$\left[\frac{2}{3},\ \frac{1}{3},\ \frac{3}{2},\ -\frac{5}{3},\ -\frac{4}{3},\ -\frac{5}{2}\right]^\top$

表 1: 一次全批量梯度下降更新前后的参数, 残差与目标函数值.

经过这次更新后目标值下降

$$\Delta J_\lambda = J_\lambda(\boldsymbol{w}^{(0)}) - J_\lambda(\boldsymbol{w}^{(1)}) = \frac{677}{108} \approx 6.269.$$

(d) 模型 A,B 的损失函数分别为

$$J_0(\boldsymbol{w}_A) = \frac{1}{N}\|\Phi\boldsymbol{w}_A - \boldsymbol{y}\|_2^2,\ \boldsymbol{w}_A = [-1, 3, 1]^\top,$$

$$J_{1/3}(\boldsymbol{w}_B) = \frac{1}{N}\|\Phi\boldsymbol{w}_B - \boldsymbol{y}\|_2^2 + \frac{1}{3}\|P\boldsymbol{w}_B\|_2^2,\ \boldsymbol{w}_B = [-1, 2, 1]^\top.$$

两个模型在验证集上的预测依次为 $[-1, 2, 0]^\top$ 和 $[-1, 1, 0]^\top$. 代入公式计算得到

model	training MSE	$\|P\boldsymbol{w}\|_2^2$	validation MSE
A	0	10	$\frac{5}{3}$
B	$\frac{2}{3}$	5	2

表 2: 模型 A 和 B 的训练 MSE, 权重惩罚与验证 MSE.

根据验证结果, 我会选择模型 A. 计算验证 MSE 时不应该加入正则惩罚, 因为验证 MSE 衡量的是预测误差, 而正则项是训练时约束参数的惩罚.

(e) 分别写出两个优化问题的目标函数

$$J_{\lambda_1}(\boldsymbol{w}) = N^{-1}\|\Phi\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \lambda_1\|P\boldsymbol{w}\|_2^2,$$

$$J_{\lambda_2}(\boldsymbol{w}) = N^{-1}\|\Phi\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \lambda_2\|P\boldsymbol{w}\|_2^2.$$

最优解分别记为

$$\boldsymbol{w}^{[1]} \in \arg\min_{\boldsymbol{w}} J_{\lambda_1}(\boldsymbol{w}),\ \boldsymbol{w}^{[2]} \in \arg\min_{\boldsymbol{w}} J_{\lambda_2}(\boldsymbol{w}),\ \lambda_2 > \lambda_1 \geq 0.$$

因此有如下不等式成立

$$J_{\lambda_1}(\boldsymbol{w}^{[1]}) \leq J_{\lambda_1}(\boldsymbol{w}^{[2]}),\ J_{\lambda_2}(\boldsymbol{w}^{[2]}) \leq J_{\lambda_2}(\boldsymbol{w}^{[1]}).$$

展开, 上不等式等价于

$$\begin{aligned} L(\boldsymbol{w}^{[1]}) + \lambda_1\|P\boldsymbol{w}^{[1]}\|_2^2 &\leq L(\boldsymbol{w}^{[2]}) + \lambda_1\|P\boldsymbol{w}^{[2]}\|_2^2, \\ L(\boldsymbol{w}^{[2]}) + \lambda_2\|P\boldsymbol{w}^{[2]}\|_2^2 &\leq L(\boldsymbol{w}^{[1]}) + \lambda_2\|P\boldsymbol{w}^{[1]}\|_2^2. \end{aligned}$$

两式相加, 移项化简得

$$(\lambda_2 - \lambda_1)(\|P\boldsymbol{w}^{[1]}\|_2^2 - \|P\boldsymbol{w}^{[2]}\|_2^2) \geq 0,$$

由于 $\lambda_2 > \lambda_1$, 因此

$$\|P\boldsymbol{w}^{[2]}\|_2^2 \leq \|P\boldsymbol{w}^{[1]}\|_2^2.$$

得到

$$L(\boldsymbol{w}^{[2]}) - L(\boldsymbol{w}^{[1]}) \geq \lambda_1(\|P\boldsymbol{w}^{[1]}\|_2^2 - \|P\boldsymbol{w}^{[2]}\|_2^2) \geq 0.$$

此即

$$L(\boldsymbol{w}^{[2]}) \geq L(\boldsymbol{w}^{[1]}).$$

增大 λ 不一定能降低验证 MSE. 正则化过强也可能导致欠拟合, 从而导致模型的泛化能力减弱, 在验证集上的 MSE 也可能增大.

(f) (c) 中的权重迭代公式为

$$\begin{aligned} \boldsymbol{w}^{(t+1)} &= \boldsymbol{w}^{(t)} - \eta\nabla_{\boldsymbol{w}} J_\lambda(\boldsymbol{w}^{(t)}) \\ &= \boldsymbol{w}^{(t)} - \eta\nabla_{\boldsymbol{w}} L(\boldsymbol{w}^{(t)}) - \eta\lambda\nabla_{\boldsymbol{w}}\|P\boldsymbol{w}^{(t)}\|_2^2 \\ &= (I - 2\eta\lambda P)\boldsymbol{w}^{(t)} - \eta\nabla_{\boldsymbol{w}} L(\boldsymbol{w}^{(t)}). \end{aligned}$$

令

$$D_c = I - 2\eta\lambda P = \mathrm{diag}(1, \frac{5}{6}, \frac{5}{6}).$$

因此

$$c = \frac{5}{6}.$$

这里 D_c 的首个对角元素为 1 是因为截距不受正则项引起的乘性衰减, 但仍按数据损失的梯度更新.

4 逻辑回归: 概率建模与分类置信度

(a) 对一般数据集 D, 似然函数写为

$$\begin{aligned}\mathcal{L}_D(t) &= \prod_{i=1}^{m} p_t(1 \mid x^{(i)})^{y^{(i)}} p_t(0 \mid x^{(i)})^{1-y^{(i)}} \\ &= \prod_{i=1}^{m} \sigma(tx^{(i)})^{y^{(i)}} (1-\sigma(tx^{(i)}))^{1-y^{(i)}},\end{aligned}$$

平均负对数似然写为

$$J_D(t) = -N^{-1}(\sum_{i=1}^{m} y^{(i)} \ln \sigma(tx^{(i)}) + (1-y^{(i)}) \ln(1-\sigma(tx^{(i)}))).$$

由于

$$J_D(t) = -N^{-1} \ln \mathcal{L}_D(t)$$

且对数函数在定义域内单调递增, 因此最大化似然等价于最小化该损失.

特别地, 对于数据集 A, B, 代入上面公式, 并利用 sigmoid 函数的性质

$$\sigma(t) + \sigma(-t) = 1,$$

得到似然

$$\begin{aligned}\mathcal{L}_A(t) &= \sigma^3(t)\sigma(-t)(1-\sigma(t))(1-\sigma(-t))^3 = \sigma^6(t)(1-\sigma(t))^2, \\ \mathcal{L}_B(t) &= \sigma^4(t)(1-\sigma(-t))^4 = \sigma^8(t).\end{aligned}$$

对似然取对数并乘以 $-1/8$, 得到平均负对数似然为

$$\begin{aligned}J_A(t) &= -\frac{1}{4}(3\ln\sigma(t) + \ln(1-\sigma(t))), \\ J_B(t) &= -\ln\sigma(t).\end{aligned}$$

(b) 利用 $\sigma'(t) = \sigma(t)(1-\sigma(t))$, 对数据集 A 的平均负对数似然求导得

$$J'_A(t) = -\frac{1}{4}(3(1-\sigma(t)) - \sigma(t)) = -\frac{1}{4}(3 - 4\sigma(t)),$$

设其为 0, 即解

$$\sigma(t) = \frac{3}{4},$$

解得

$$t = \ln 3.$$

再对 t 求导, 由于有限 t 下 $0 < \sigma(t) < 1$, 得到

$$J_A''(t) = \sigma(t)(1 - \sigma(t)) > 0,$$

因此 $J_A(t)$ 是关于 t 的严格凸函数, 驻点 $t = \ln 3$ 是唯一全局最小值点, 对应最优权重向量

$$\boldsymbol{w} = (\ln 3).$$

同理, 对数据集 B 的平均负对数似然求导

$$J_B'(t) = \sigma(t) - 1,$$

由于 sigmoid 函数

$$\sigma(t) = \frac{1}{1 + e^{-t}} < 1,$$

因此 $J_B'(t) < 0$, 目标严格递减, 不存在有限最优参数. 又因为

$$J_B(t) = \ln(1 + e^{-t}) > 0, \qquad \lim_{t \to +\infty} J_B(t) = 0,$$

所以 $\inf_{t \in \mathbb{R}} J_B(t) = 0$, 但任何有限参数都不能达到这个下确界.

容易从数据集 A,B 中数据点的分布情况看出端倪. 对于数据集 A 中的两个特征取值 $x = -1$ 和 $x = 1$, 两个标签 $y \in \{0, 1\}$ 都有观测, 参数绝对值无限增大会使部分样本的真实标签概率趋于零, 因此最优参数有限. 而对于数据集 B, 对于特征 $x = -1$, 其对应标签只有 $y = 0$; 对于特征 $x = 1$, 其对应标签只有 $y = 1$. 因此随着 $t \to +\infty$, 所有训练样本的真实标签概率都趋于 1, 损失趋近下确界 0.

(c) 由于 $t > 0$ 且分类阈值为 $\frac{1}{2}$, 因此决策边界为

$$p_t(1 \mid x) = \sigma(tx) = \frac{1}{2} \iff x = 0,$$

线性放大参数 t 不影响决策边界.

由于 $c > 1$ 时 tx 与 ctx 的符号相同, 放大前后对 B 的全部样本均分类正确, 分类错误率都为 0.

对 B 中的两种样本 $(x, y) = (-1, 0)$ 和 $(1, 1)$, 模型赋予真实标签的预测概率均从 $\sigma(t)$ 增大到 $\sigma(ct)$.

数据集 B 的平均负对数似然

$$J_B(ct) = -\ln \sigma(ct) < -\ln \sigma(t) = J_B(t),$$

在参数放大后减小. 分类错误率只反映预测类别是否正确, 而负对数似然还取决于赋予真实标签的概率, 所以错误率不变时损失仍可下降.

(d) 下面两种说法均错误.

1. 在 B 上, 任意 $t > 0$ 的分类错误率都为零, 但继续增大 t 仍能降低负对数似然, 且任何有限 t 都不能达到下确界 0.
2. 训练样本的真实标签概率提高不能保证同分布测试集的平均负对数似然下降. 一旦对测试样本预测错误, 更加自信反而会增大该样本的负对数似然.

在目标函数 $J_B(t)$ 中加入二次正则项 λt^2 ($\lambda > 0$) 后, 当 $|t| \to \infty$ 时, $\lambda t^2 \to +\infty$. 由于 $J_B(t) \geq 0$, 总目标也趋于 $+\infty$, 因此无限增大权重不能使总目标更优.