FAIML Lab1 实验报告

王子川 PB25000055

2026 年 10 月 20 日

1 思考题

1.1 重现 ℓ_1, ℓ_2 正则化的系数路径

前 2 道思考题我使用了公开的 UCI Auto MPG 数据集 [1]. 该数据集用于根据汽车参数预测城市工况下的燃油经济性 `mpg`. 原始数据共有 398 辆汽车, 清洗后保留 392 个样本. 选取 `cylinders`, `displacement`, `horsepower`, `acceleration`, `model_year` 共 5 个数值特征做线性回归.

固定随机种子 2026, 按 8 : 2 随机划分训练集和测试集, 得到 $N = 313$ 个训练样本和 79 个测试样本. 使用训练集计算每个特征的均值和标准差, 再用同一变换标准化测试集. 统一采用目标函数

$$J(w, b) = N^{-1}\|Xw + b\mathbf{1} - y\|_2^2 + \lambda_1\|w\|_1 + \lambda_2\|w\|_2^2. \tag{1}$$

考察 Lasso 时令 $\lambda_2 = 0$, 考察 Ridge 时令 $\lambda_1 = 0$, 不惩罚偏置. 均在 $[10^{-3}, 10^2]$ 上取 120 个对数等距点. 调用 sklearn 时令 $\alpha_{\text{Lasso}} = \lambda_1/2$, $\alpha_{\text{Ridge}} = N\lambda_2$, 以匹配式 (1).

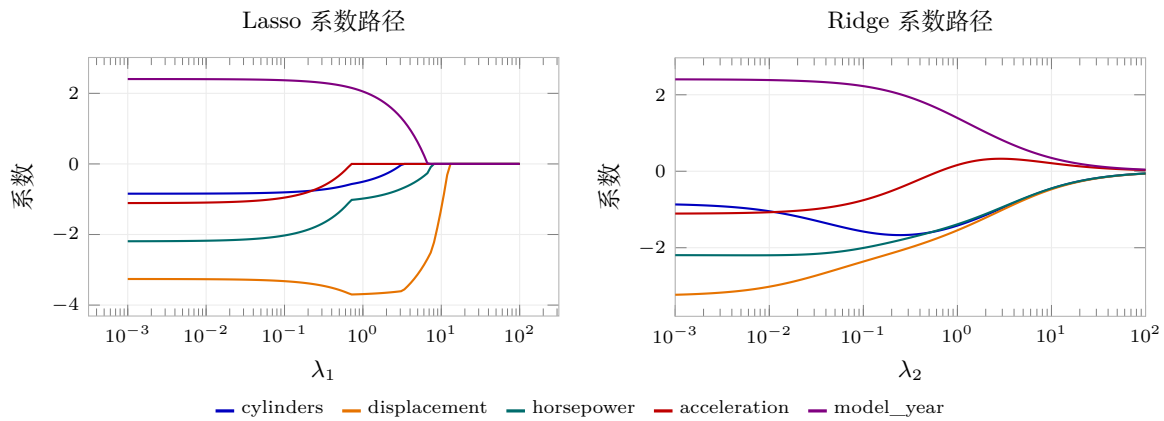


图 1: Auto MPG 数据集上的 ℓ_1 与 ℓ_2 正则化系数路径. 两图使用同一训练划分和标准化特征.

从图中可以看到, 当正则化强度较小时, 两种方法都接近未正则化的线性回归解. 随着 λ_1 增大, Lasso 的部分系数会在有限的正则化强度下精确变为 *0*, 从而产生稀疏解. Ridge 的系数整体随 λ_2 增大而收缩, 单个相关变量的系数不一定单调变化, 但在有限的 λ_2 下通常不会精确变成 *0*. 因此, Lasso 在优化过程中同时完成收缩和变量筛选, 而 Ridge 更适合对一组相关变量进行平滑收缩.

1.2 为什么直接截断 Ridge 的小系数可能破坏特征选择?

Auto MPG 在这一问题上非常直观. 在训练集上, 三个发动机变量之间具有很强的线性相关性:

$$\text{corr}(\text{cylinders}, \text{displacement}) = 0.953,$$

$$\text{corr}(\text{cylinders}, \text{horsepower}) = 0.853, \quad \text{corr}(\text{displacement}, \text{horsepower}) = 0.900.$$

也就是说, 它们确实在描述相近的发动机规模和动力信息.

先在训练集内部使用 10 折交叉验证选择 Ridge 的正则化参数, 折内独立拟合标准化统计量. 在 $[10^{-3}, 10^{3}]$ 内搜索 121 个对数等距的 sklearn 参数 α, 按平均验证 MSE 选择后在全部 313 条训练数据上重新拟合. 得到

$$\lambda_2 = 0.04022.$$

在标准化特征上拟合后, 系数为

表 1: 交叉验证选择参数后的标准化 Ridge 系数.

特征	Ridge 系数
`cylinders`	-1.359
`displacement`	-2.651
`horsepower`	-2.140
`acceleration`	-0.954
`model_year`	2.328

可以看到, 强相关的发动机变量并没有出现某一个系数绝对占主导的情况. 例如 `cylinders` 和 `horsepower` 的系数绝对值分别为 1.359 和 2.140. 这是 Ridge 在相关变量之间分摊预测作用的典型现象. 因此, 每个系数看起来不大, 并不代表这一组变量整体没有预测信息.

若在 Ridge 拟合完成后使用硬阈值

$$\widetilde{w}_j = w_j \mathbf{1}\{|w_j| \geq \tau\},$$

测试误差会出现明显的离散跳变:

表 2: 对 Ridge 系数进行事后硬截断的结果.

τ	非零系数数	测试 MSE
0.00	5	15.187
1.00	4	15.913
1.70	3	17.072
2.15	2	23.560
2.40	1	36.604
2.70	0	63.035

当 $\tau = 2.15$ 时, `cylinders`, `horsepower` 和 `acceleration` 会被直接删除, 测试 MSE 从 15.187 增加到 23.560. 为了排除 `acceleration` 的影响, 再单独对相关发动机变量做消融:

表 3: 只将指定 Ridge 系数置零时的测试误差.

置零的系数	测试 MSE
无	15.187
`cylinders`	17.508
`horsepower`	20.314
`cylinders` + `horsepower`	27.011
`cylinders` + `displacement` + `horsepower`	50.260

这个结果直接说明了问题: **Ridge 系数的绝对值本身不能作为独立的特征重要性判据**. 高度相关的变量会共同承担同一部分预测信息, 因而某个系数较小并不意味着对应变量可以安全删除. 特别是同时删

除多个相关变量时, 原本分散在这一组变量中的有效信息会一起丢失. Lasso 与这种事后截断不同, 它把稀疏性直接写入优化目标, 因而变量删除是在重新平衡拟合误差与正则化代价的过程中完成的.

1.3 与 sklearn 实现的拟合效果有何差异?

使用相同数据, 训练集预处理统计量, 自由偏置及纯 ℓ_2 目标. 按目标函数归一化匹配参数: Ridge 取 $\alpha = N\lambda_2$, 逻辑回归取 $C = 1/(2N\lambda_2)$[3, 5].

表 4: 同一目标函数下的对照.

项目	地理坐标回归	真假逻辑回归
特征层	11	23
(λ_1, λ_2)	$(0, 0.3)$	$(0, 0.01)$
sklearn 参数	$\alpha = 150$	$C = 0.00982704$
自写 GD 验证 MSE / BCE	151.008582600	0.314450299
sklearn 验证 MSE / BCE	151.008582395	0.314503202
自写 GD / sklearn 验证准确率	—	87.33% / 87.33%
最大坐标 / 概率差	3.11×10^{-7} deg	0.003426
验证集分类结果不同的样本数	—	0

线性回归的验证预测在数值精度范围内一致. 逻辑回归的 300 条验证分类结果也完全相同; 小幅概率差主要来自优化精度, 其中自写 GD 达到 10000 次上限, 尚未满足 10^{-5} 的梯度残差标准. 自写实现见 `model.py`; 基础实验的真假模型使用第 1.9 节的近端优化.

1.4 地理坐标预测: 层次比较与选择

使用 Qwen3-4B-Base 第 11, 23, 35 层表征, 每个样本为国名最后一个词元的 2560 维向量. 训练集 500 条, 验证集 130 条, 将特征转为 float64 后训练. 纬度, 经度分别拟合一个线性模型. 层次和超参数统一按验证集的原始坐标 MSE 选择:

$$\mathrm{MSE} = \frac{1}{2N} \sum_{i=1}^{N} \left[(\widehat{\phi}_i - \phi_i)^2 + (\widehat{\lambda}_i - \lambda_i)^2 \right],$$

其中 ϕ 为纬度, λ 为经度, 单位为 deg. 每个输出各自的训练目标仍为式 (1).

表 5: 各层在已搜索配置中的最好结果, 三行均采用训练集中心化.

层数	λ_1	λ_2	训练 MSE	验证 MSE	验证平均距离 / km
11	0	0.3	105.004	**151.009**	**1142.1**
23	0	0.3	73.261	221.436	1504.6
35	1	3	69.428	195.290	1407.0

因此, 在基础实验的候选范围内选定第 11 层. 后两层虽训练误差更小, 验证误差却更大, 说明训练拟合更好并不保证泛化更好. 一种可能解释是不同层的信息经过重新组织, 对坐标的线性可读性不同; 但本实验只能支持 “在这些数据, 层次与配置中, 第 11 层最好”, 无法据此断言所有浅层都更适合地理任务.

训练损失随迭代的变化　对选定的第 11 层, 采用零初始化, BGD, 学习率 0.00820656, $\lambda_1 = 0$, $\lambda_2 = 0.3$. 训练时特征和标签均按训练集均值中心化, 导出预测时恢复标签均值. 每轮分别记录

$$J_t = \underbrace{N^{-1}\|Xw_t + b_t\mathbf{1} - y\|_2^2}_{\text{MSE 数据项}} + \underbrace{\lambda_1\|w_t\|_1}_{\ell_1\text{ 项}} + \underbrace{\lambda_2\|w_t\|_2^2}_{\ell_2\text{ 项}}.$$

绘制上式各项的迭代变化曲线.

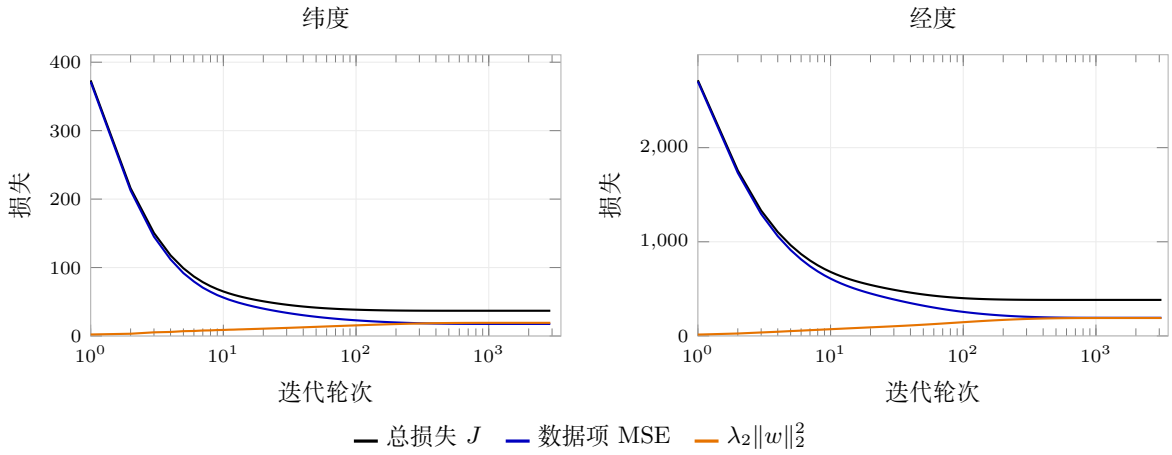


图 2: 第 11 层基础模型的训练损失分解. 横轴采用对数刻度, 从第 1 次更新画至各自收敛.

纬度与经度分别在 2910 和 3116 次更新后停止. 最终纬度的 MSE, ℓ_2 项, 总损失分别为 17.656, 19.236, 36.892; 经度分别为 192.352, 190.139, 382.492. 可以看出: MSE 随拟合下降, 正则项从零增大后稳定, 总损失下降至稳定值.

上述第 11 层是助教提供的三个候选层中的最优选择. 附加实验进一步对全部 36 层进行搜索, 并使用 6500 条训练数据重新验证, 最终选定第 9 层作为提交模型的特征层, 详见第 2.2 节.

1.5　地理坐标预测: 正则化如何选择?

对第 11, 23, 35 层及中心化, 标准化两种预处理进行网格搜索. 对 λ_2 先在给定粗网格上搜索, 再在当前最优非零候选附近进行对数尺度细化, 并以验证集 MSE 选择配置. 在基础实验的候选范围内选得第 11 层, $\lambda_1 = 0, \lambda_2 = 0.3$. 由于 $N = 500 < D = 2560$, 无正则化模型可将训练误差压至接近 0, 但验证 MSE 为 395.021; 加入适量 ℓ_2 正则化后, 验证 MSE 降至 151.009.

$\lambda_1 \times \lambda_2$ 三层网格　为比较不同层对正则化强度的敏感程度, 将原第 11 层网格扩展到第 23, 35 层. 三层共用相同的 500 条训练数据和 130 条验证数据, 均仅由训练集计算均值并中心化特征, 不缩放标签. 不进行标准化是由于输入为大语言模型的隐状态表征而非具有不同物理量纲的人工特征, 这样做能够保留隐藏维度间原有的尺度信息; 同时通过中心化消除特征均值偏移, 并由 Ridge 正则化控制高维特征带来的过拟合. 纬度和经度分别最小化式 (1), 两个输出使用同一组参数, 偏置不惩罚. 各层使用相同候选值:

$$\lambda_1 \in \{0, 0.01, 0.1, 0.3, 1, 10, 100\},$$
$$\lambda_2 \in \{0, 0.01, 0.1, 0.3, 1, 3, 10\}.$$

每层 7×7 个配置, 共 147 个格点; 第 11 层复用已核验的 49 个记录, 第 23, 35 层新增 98 个配置. 纯 Ridge 使用 NumPy 解析解; 含 ℓ_1 的格点使用 sklearn ElasticNet 坐标下降, 令 $\alpha = \lambda_1/2 + \lambda_2$, l1_ratio $= \lambda_1/(\lambda_1 + 2\lambda_2)$, 使目标函数与式 (1) 等价 [2]. 每个输出最多迭代 300000 次, 另以最大 KKT 残差小于 10^{-4} 判断收敛. 共 145 个格点满足标准, 其余 2 个标为灰色叉号, 不参与选优.

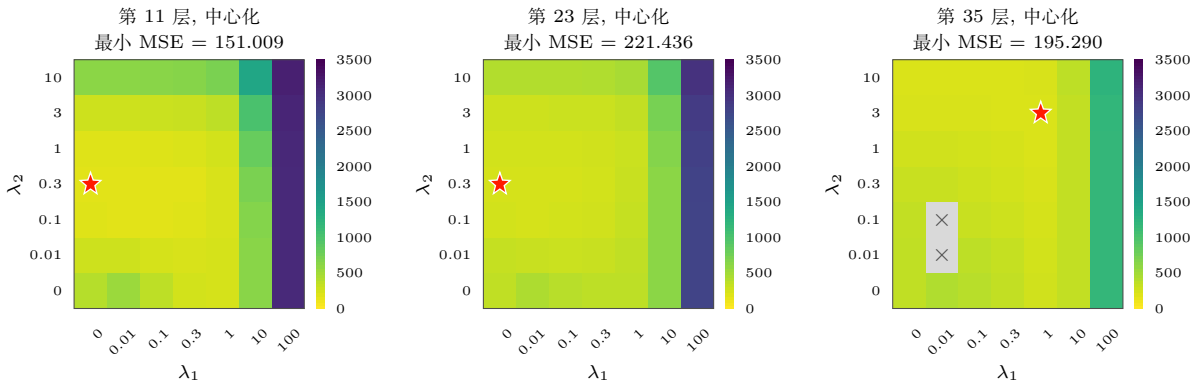


图 3: 地理坐标预测的 $\lambda_1 \times \lambda_2$ 验证 MSE 热力图, 单位为 deg^2. 三图统一色标, 越亮表示 MSE 越小; 红星为各图内已收敛正则化配置的验证 MSE 最小点. 灰色 × 表示未收敛; 无正则化的 $(0, 0)$ 均不参与选优.

本实验采用验证集选参, 不是交叉验证. 第 11, 23, 35 层红星对应的 (λ_1, λ_2) 依次为 $(0, 0.3)$, $(0, 0.3)$, $(1, 3)$, 验证 MSE 依次为 151.009, 221.436, 195.290. 在这批数据和已收敛的网格候选中, 第 11 层最好, 选定正则化参数 $(\lambda_1, \lambda_2) = (0, 0.3)$.

1.6 地理坐标预测: 验证结果与地图

选取第 11 层, 中心化预处理, $(\lambda_1, \lambda_2) = (0, 0.3)$. 在原始特征上预测时, 预处理已折叠进导出的权重和偏置.

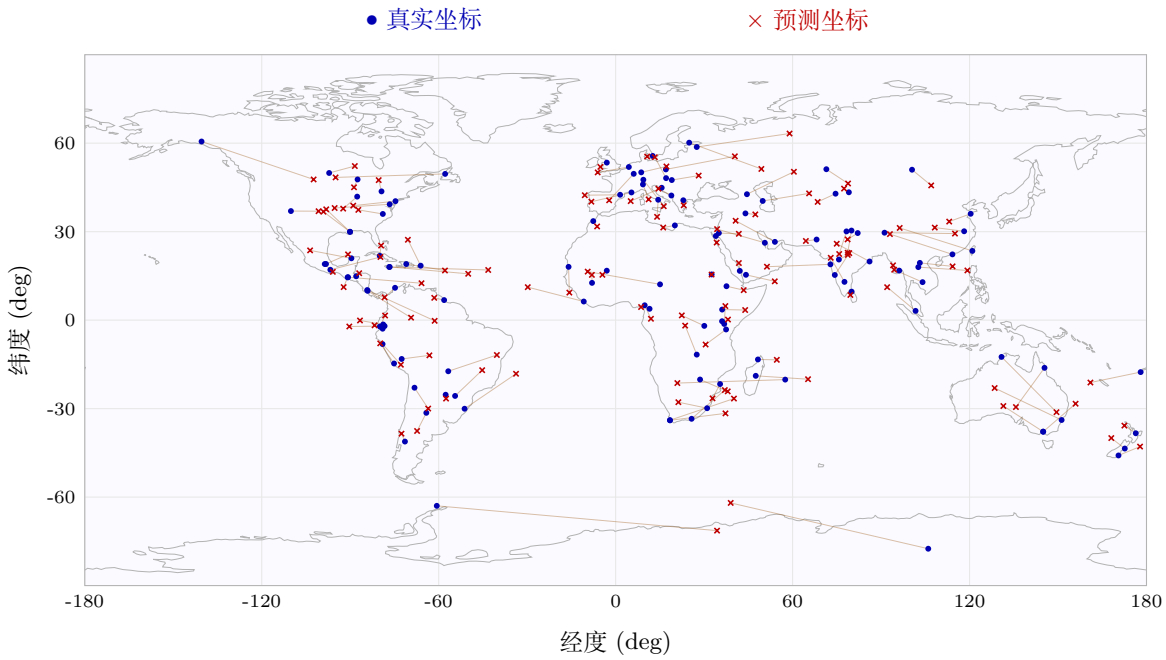


图 4: 基础实验第 11 层在全部验证样本上的真实位置与预测位置. 浅棕色线连接同一样本; 底图使用 Natural Earth 1:110m 海岸线 [6].

表 6: 基础实验第 11 层地理模型的误差 (RMSE 为均方根误差, 距离按半径 6371.0088 km 的球面 Haversine 公式计算).

指标	训练集	验证集
经纬度联合 MSE (deg^2)	105.004	151.009
纬度 RMSE (deg)	4.202	5.531
经度 RMSE (deg)	13.869	16.475
纬度 / 经度 R^2	0.9789 / 0.9699	0.9636 / 0.9530
平均 / 中位距离误差 (km)	835.2 / 639.8	1142.1 / 958.0
距离误差不超过 1000 km 的比例	71.20%	54.62%

模型能够恢复大致空间位置, 但平均误差仍超过 1000 km, 不能视为精确定位. MSE 对经纬度直接平方, 没有体现经度跨 $\pm 180^\circ$ 的周期性及纬度对经度距离的影响, 因此同时报告球面距离. 上述基础模型的 130 个预测均未越过合法经纬度范围, 无需截断来改善这些结果.

1.7 这些结果能否强烈证明模型具有地理坐标表征?

还不能. 线性模型能够从隐藏层表征中预测地理坐标, 但这并不足以证明模型掌握了具体地点的位置信息. 模型可能主要依据国家信息预测该国的典型位置, 而非区分同一国家内的不同地点 [7].

为检验这一可能性, 本节构造基线 (baseline): 仅在训练集内按原始 `country` 字符串分组, 取每组经纬度平均值作为预测; 验证样本所属字符串在训练集未出现时, 回退为训练集全局平均坐标. 验证集分成已见国家字符串 110 条, 未见国家字符串 20 条, 不使用验证标签计算任何均值.

表 7: 线性探测与国家均值基线的比较. 距离列单位为 km, MSE 单位为 deg^2.

样本组	模型 MSE	基线 MSE	模型平均距离	基线平均距离
训练集全部 (500)	105.004	140.509	835.2	668.4
验证集全部 (130)	151.009	278.240	1142.1	1297.1
验证: 已见字符串 (110)	148.755	**113.769**	1079.9	**689.5**
验证: 未见字符串 (20)	**163.403**	1182.832	**1484.2**	4638.9

总体上模型超过国家均值基线, 但在已见国家组内, 模型反而弱于基线. 总体优势很大程度来自未见国家组, 而该组基线只输出全局均值, 本身较弱. 因此不能把总体 MSE 的改善直接当作模型精确区分同一国家内地点的证据.

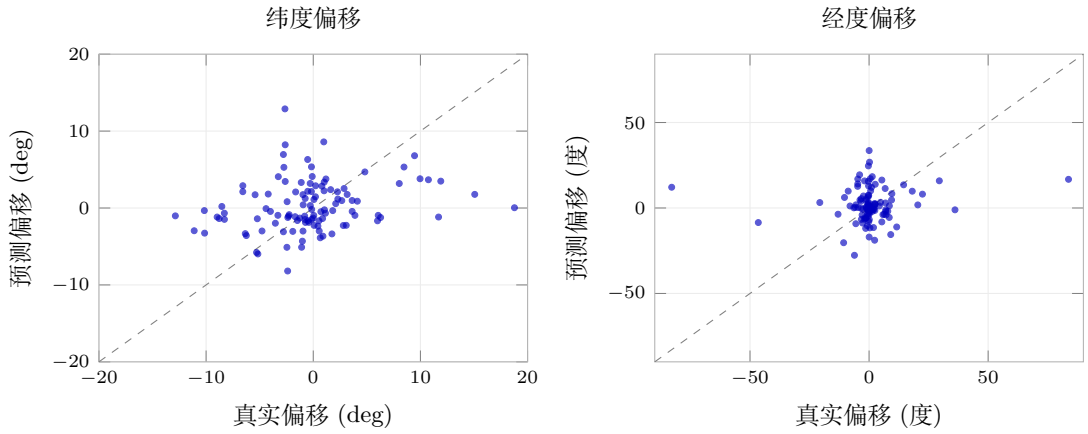


图 5: 已见国家组中, 真实和预测坐标分别减去对应训练集国家均值后的偏移. 虚线为理想预测; 国家均值基线的预测偏移恒为零. 经度偏移按原始度数计算.

散点存在明显偏差, 结合分组误差, 推出当前实验表明: 表征中包含可线性读取的粗粒度地理信息, 但还不足以排除国家或其他文本线索的作用.

1.8 真假预测: 训练集与验证集有哪些分布差异, 如何应对?

下表对训练集和验证集的样本进行统计分析.

表 8: 文本分布审计. 句长采用按空白切分的词数; “词表” 按小写正则表达式 `[a-z]+` 统计.

项目	训练集	验证集
样本数	5088	300
真 / 假样本数	2544 / 2544	150 / 150
平均 / 中位句长	10.32 / 9	9.32 / 9
最大句长	72	25
句长至少 13 的比例	21.70%	10.67%
假句 / 真句的平均句长	10.15 / 10.49	9.14 / 9.50
词表大小	8565	1147
完全相同句数	0	0

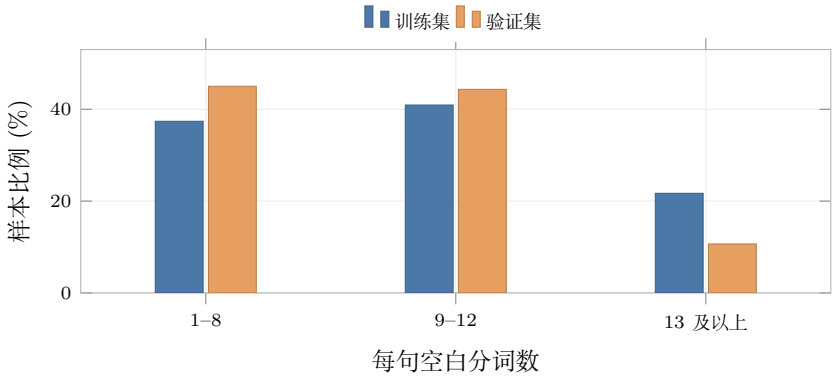


图 6: 句长分布不同: 验证集中短句更多, 长句所占比例约为训练集的一半.

训练集与验证集没有完全相同或规范化后相同的句子. 验证集的 2794 个正则分词结果中, 有 516 个

未出现在训练词表中, 占 18.47%, 说明两者的词汇覆盖存在一定差异. 不过, 专有名词和拼写错误也会产生未见词, 因此不能仅据此判断存在明确的主题偏移.

两集合均存在语病或拼写噪声, 真假判断也可能涉及常识, 实体及语境. 例如验证句 *"Dodo's can no longer be fuond anwyhere on this earth."* 含明显拼写错误, 标注为真, 模型给出真概率 0.0768; *"Telling someone they are a nerd is a compliment to many."* 标注为假, 模型给出真概率 0.9425. 它们是相对数据标注的错例, 不能仅凭模型输出认定标签有误, 也不能把所有错误都归因于拼写.

为提高模型的泛化能力, 本实验通过验证集选择特征层次与正则化参数, 以缓解高维特征下的过拟合, 并仅使用训练集计算预处理统计量, 避免数据泄漏. 此外, 构造仅使用字符数和词数的简单基线, 其验证准确率为 53.33%, AUC 为 0.5476, 表明句长信息本身不足以解释线性探针的预测性能. 不过, 上述方法并未直接校正训练集与验证集在句长, 词汇及文本噪声方面的分布差异, 因而不能保证完全消除分布偏移对模型的影响.

1.9 真假预测: 如何选择层次与正则化?

输入为句子最后一个词元的 2560 维表征, 标签 1 表示真, 0 表示假. 比较第 11, 23, 35 层和中心化, 标准化两种预处理. 每组搜索 12 个配置: 纯 ℓ_2 的 $\lambda_2 \in \{10, 1, 0.1, 0.01, 0.001, 0.0001\}$; 纯 ℓ_1 的 $\lambda_1 \in \{0.01, 0.001, 0.0001\}$; 混合 $(\lambda_1, \lambda_2) \in \{(0.001, 0.01), (0.0001, 0.001)\}$; 以及无正则化诊断组. 共 72 个候选, 58 个在 3000 次上限内达到 10^{-5} 的 KKT 残差标准. 最终只在已收敛的正则化候选中, 先按验证准确率, 同分时按 BCE 选择.

表 9: 各层选出的最好正则化配置. 准确率采用固定阈值 0.5.

层	预处理	λ_1	λ_2	训练准确率	验证准确率	验证 BCE
11	标准化	0	0.1	81.54%	75.67%	0.52265
23	中心化	0.001	0.01	94.26%	**88.00%**	**0.29755**
35	标准化	0.001	0.01	92.32%	82.33%	0.41411

表 10: 各正则化家族的最好候选; 恰好均为第 23 层, 中心化.

正则化	训练准确率	验证准确率	验证 BCE	非零系数数
无正则化	100.00%	86.00%	1.57415	2560
ℓ_1, $\lambda_1 = 0.001$	96.86%	87.33%	0.35435	951
ℓ_2, $\lambda_2 = 0.01$	96.19%	87.33%	0.31451	2560
$\ell_1 + \ell_2$, 0.001 / 0.01	94.26%	**88.00%**	**0.29755**	1442

在基础实验的候选范围内选定第 23 层, 中心化, $\lambda_1 = 0.001, \lambda_2 = 0.01$. ℓ_1 使 1118 个系数为零, ℓ_2 约束剩余权重规模; 与无正则化组相比, 降低训练拟合程度却改善了验证 BCE. 这支持适量正则化的选择, 但相对纯 ℓ_2 的准确率只多正确 2 个样本, 不能夸大为稳定优势. 中间层在本题优于第 11, 35 层, 可能与真实性相关信息的线性可读性有关, 仍需更多独立数据验证.

$\lambda_1 \times \lambda_2$ 三层网格 为展示正则化强度的影响, 在同一训练集 (5088 条) 和验证集 (300 条) 上补齐二维网格, 两轴均取 $\{0, 0.001, 0.01, 0.1, 0.2, 0.5, 1\}$. 第 11, 35 层固定使用标准化, 第 23 层固定使用中心化, 均仅由训练集计算预处理统计量. 每层 7×7 个配置, 共 147 个格点; 24 个复用已核验的原实验记录, 123 个新增训练. 目标函数仍为 $\mathrm{BCE} + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$, 偏置不正则化, 迭代上限和收敛标准保持不变. 共 145 个格点收敛, 其中 144 个正则化配置参与选优.

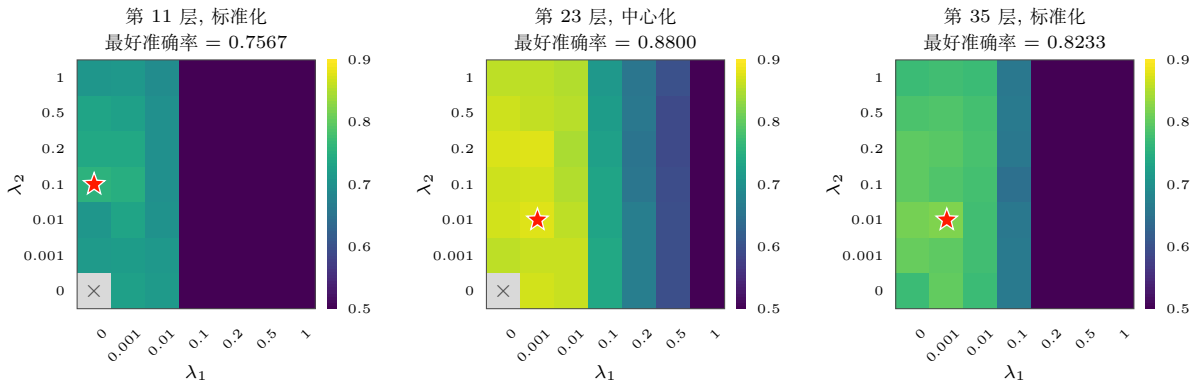


图 7: 真假预测的 $\lambda_1 \times \lambda_2$ 验证准确率热力图. 三图统一色标, 越亮越好; 红星为各图内已收敛正则化配置的验证集最优点, 同分按 BCE 选取. 灰色 × 表示未收敛; 无正则化的 $(0, 0)$ 均不参与选优. 两轴按候选值等距排列.

网格内选择的三组最优参数均与上表一致. 当 λ_1 过大时, 部分配置的权重全部为零, 验证准确率降至 50%, 表现为欠拟合. 三图采用各层原先选出的预处理方式, 因此跨图差异同时包含层次与预处理的影响. 本图采用验证集选参, 不属于交叉验证.

优化过程 用 NumPy 实现带回溯和动量重启的加速近端梯度. 对 BCE 和 ℓ_2 做梯度步 $u = w - \eta\nabla(\mathrm{BCE} + \lambda_2\|w\|_2^2)$, 再做软阈值 $w_j \leftarrow \mathrm{sgn}(u_j)\max(|u_j| - \eta\lambda_1, 0)$; 偏置不做阈值化. 上述第 23 层基础模型迭代 675 次, KKT 残差为 9.01×10^{-6}, 满足标准.

训练损失随迭代的变化 沿用上述第 23 层配置, 在 5088 条训练样本上从零初始化, 每次更新后记录

$$J_t = \underbrace{-\frac{1}{N}\sum_{i=1}^{N}\big[y_i \log p_{i,t} + (1-y_i)\log(1-p_{i,t})\big]}_{\text{BCE 数据项}} + \underbrace{\lambda_1\|w_t\|_1}_{\ell_1\ \text{项}} + \underbrace{\lambda_2\|w_t\|_2^2}_{\ell_2\ \text{项}}, \qquad p_{i,t} = \sigma(x_i^{\mathsf{T}} w_t + b_t).$$

其中 x_i 为按训练均值中心化的特征, $\lambda_1 = 0.001$, $\lambda_2 = 0.01$, 偏置不正则化. 图 8 与线性回归损失图采用相同的对数横轴和配色.

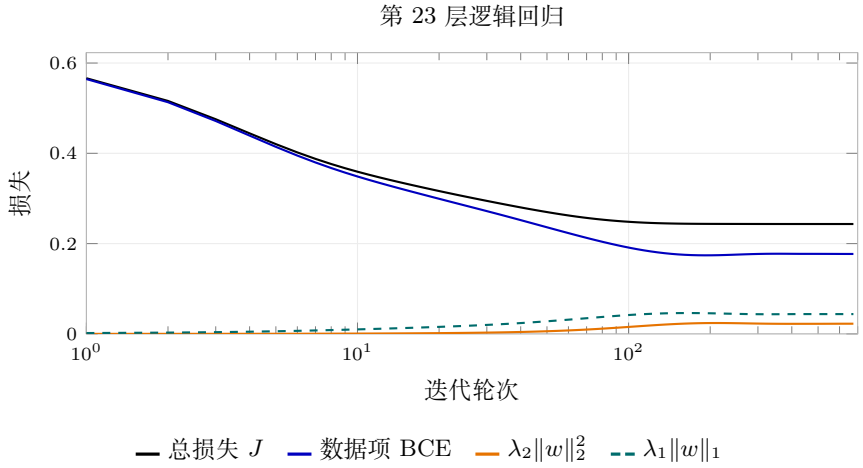


图 8: 第 23 层基础逻辑回归模型的训练损失分解. 横轴采用对数刻度, 从第 1 次更新画至第 675 次收敛.

零初始化时 BCE 与总损失均为 $\log 2 \approx 0.69315$, 两个正则项为零. 最终 BCE, ℓ_1 项, ℓ_2 项分别为 0.17704, 0.04383, 0.02252, 总损失为 0.24338. BCE 与总损失总体下降后趋于稳定, 正则项随权重形成逐渐稳定, 体现拟合与复杂度约束的折中.

最终评估　验证混淆矩阵的行为真实标签, 列为预测标签, 顺序均为 0, 1:

	$\widehat{y}=0$	$\widehat{y}=1$
$y=0$	125	25
$y=1$	11	139

$$\text{Accuracy} = 264/300 = 88.00\%,$$
$$\text{Precision} = 84.76\%, \quad \text{Recall} = 92.67\%,$$
$$F_1 = 0.88535, \quad \text{AUC} = 0.94809.$$

训练准确率为 94.26%, 验证集仍有 36 个错误, 其中将假判为真 25 次, 将真判为假 11 次.

ROC 可视化　对基础实验第 23 层模型的预测概率改变判别阈值 t, 以 $\widehat{p} \geq t$ 判为真, 以假阳性率为横轴, 真阳性率为纵轴, 得到图 9. 两者定义为

$$\text{FPR} = \frac{\text{FP}}{\text{FP}+\text{TN}}, \qquad \text{TPR} = \frac{\text{TP}}{\text{TP}+\text{FN}}.$$

原阈值 $t = 0.5$ 对应 FPR = 0.1667, TPR = 0.9267. AUC 为 0.94809, 反映模型对正负样本的排序能力; 它与固定阈值下的 88.00% 准确率含义不同.

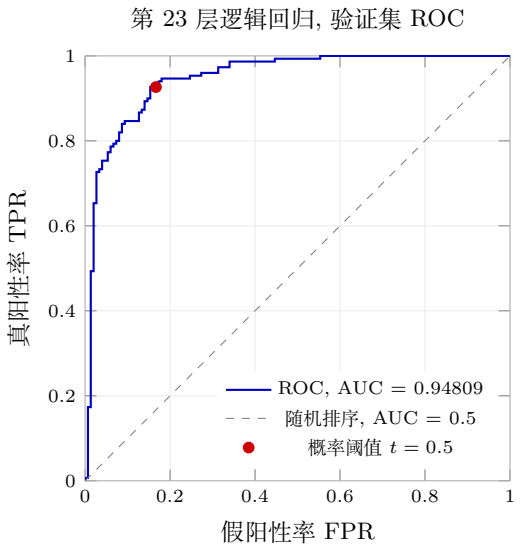


图 9: 基础实验第 23 层模型在 300 条验证样本上的 ROC. 使用连续预测概率改变判别阈值, 标签 1 为正类; 红点是原混淆矩阵对应的阈值 0.5.

所有层次及正则化选择都复用了验证集, 所以这些是调参后的验证结果, 并非独立测试成绩. 上述比较限于第 11, 23, 35 层. 附加实验进一步比较全部 36 层, 在相同搜索规则下第 20 层取得最高验证准确率, 详见第 2.4 节.

2 附加内容

2.1 数据扩增对地理位置预测的影响

2.1.1 500 条数据的全层探索与层数选择

基础题只在 TA 提供的第 11, 23, 35 层中比较, 因而选定第 11 层. 为确定附加实验的固定层数, 进一步提取全部 36 层特征. 该探索使用原始 500 条训练数据和 130 条验证数据, 模型为 Qwen3-4B-Base, 取国名末词元对应的 2560 维表示, 层编号为 0–35.

各层分别比较中心化和标准化, 两者的统计量都只从训练集计算. 令 $\lambda_1 = 0$, 按式 (1) 对两个坐标分别求 Ridge 解析解. λ_2 的粗网格为

$$\{0, 10^{-4}, 10^{-3}, 10^{-2}, 0.1, 1, 3, 10, 30, 100, 300, 1000, 3000, 10000\},$$

对非零粗网格最优值再在其 1/3 至 3 倍范围内取 9 个对数等距点, 去掉重复值, 共比较 1536 个配置. 按验证集原始坐标 MSE 选出每层配置, 再比较层次. 本次通过已保存的 36 组原坐标权重重新计算训练和验证 MSE, 与原记录一致.

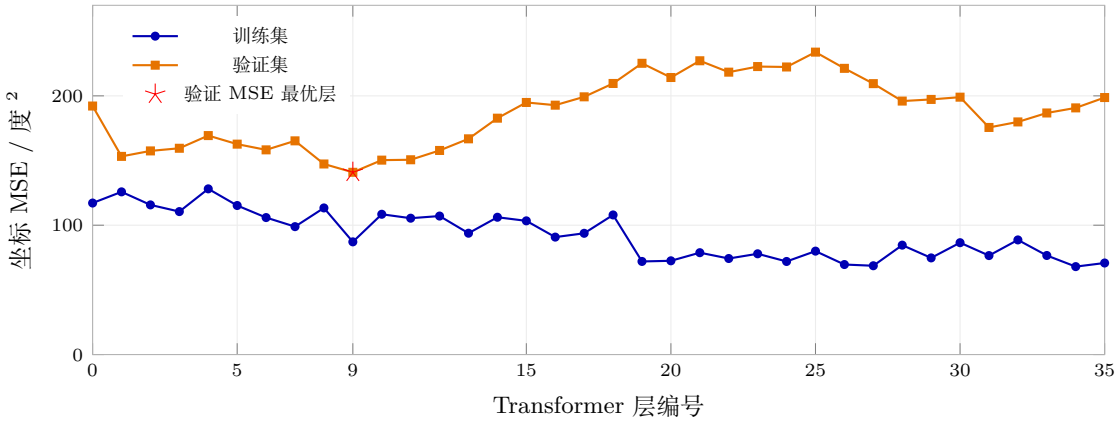


图 10: 500 条训练数据的全层探索. 每个点对应该层按验证 MSE 选出的预处理和 Ridge 系数.

全部候选中第 9 层最好: 中心化, $\lambda_2 = 0.2279507$, 训练 MSE 为 87.131, 验证 MSE 为 $140.907\,\mathrm{deg}^2$. 同批特征下, 第 11 层的最优验证 MSE 为 $150.591\,\mathrm{deg}^2$. 因此, 后续数据量消融实验选用第 9 层, 但其优势目前仅在原始 500 条训练数据和当前 Ridge 回归设置下得到验证.

2.1.2 固定第 9 层的数据量消融

实验设计 采用三组嵌套训练集: 原始 `train.csv` 的 500 条; 原始数据加第一次增广的 3000 条, 共 3500 条; 再加入第二次增广的 3000 条, 共 6500 条. 新增地点及对应地理位置数据由 ChatGPT 辅助生成. 验证集均为同一份 `valid.csv` 的 130 条, 不参与训练或预处理统计量计算. 按规范化的地点名与国家键检查, 未发现增广数据与 `train.csv` 和 `valid.csv` 中的地点重叠.

三组均提取第 9 层特征, 将特征转为 float64 后训练. 每组仅用自身训练数据估计均值和标准差, 分别标准化训练及验证特征. 两维经纬度标签用弧度表示, 统一最小化

$$J_N = \frac{1}{N}\sum_{i=1}^{N}\left[(\widehat{\phi}_i - \phi_i)^2 + (\widehat{\lambda}_i - \lambda_i)^2\right] + \lambda_{\mathrm{reg}}\|W\|_F^2, \quad \lambda_{\mathrm{reg}} = 0.01.$$

偏置不正则化, 不使用 ℓ_1 项, 不为各数据量单独调参. 这里使用标准化输入和固定系数, 与前面的中心化调参最优配置不同; 第 9 层是预先选定的研究对象, 没有声称其在本配置下仍为全层最优.

评估结果　三个 Ridge 模型均满足最大梯度绝对值小于 10^{-7}. 实际定位误差使用地理

$$\mathrm{RMSE}_{\mathrm{geo}} = \sqrt{N_v^{-1} \sum_i (R\gamma_i)^2}, \quad R = 6371.0088\,\mathrm{km}.$$

其中 γ_i 为真实与预测坐标的球心角, 由对应单位向量计算; 不裁剪原始纬度.

表 11: 第 9 层固定配置下的数据扩增结果. 后四列均在同一 130 条验证数据上计算.

训练数量	训练 MSE (deg^2)	验证 MSE (deg^2)	地理 RMSE (km)	平均距离 (km)	1000 km 内比例
500	0.683	353.012	2504.367	1798.550	34.62%
3500	163.844	301.276	2259.261	1546.280	46.92%
6500	156.735	180.335	1734.716	1225.655	52.31%

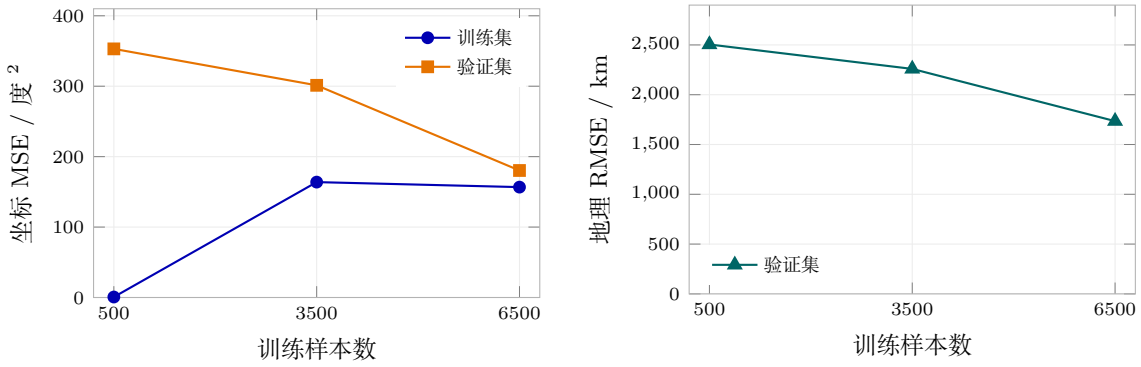


图 11: 固定第 9 层, 标准化输入及 $\lambda_{\mathrm{reg}} = 0.01$ 的数据量消融, 三组训练集按增广批次嵌套.

结果分析　从 500 增至 3500 条, 验证地理 RMSE 降低 9.79%; 从 3500 增至 6500 条再降低 23.22%. 6500 条相对 500 条的地理 RMSE 总计降低 30.73%, 坐标 MSE 降低 48.92%, 1000 km 内比例由 34.62% 提高到 52.31%; 130 个地点中有 87 个距离误差减小. 本实验第二次增广的收益更大.

500 条时训练 MSE 仅 0.683, 验证 MSE 却为 353.012, 表明高维特征下这套固定配置能很好拟合小训练集, 但泛化误差较大. 增广后训练误差上升而验证误差下降, 训练与验证的差距缩小; 由于训练集本身也发生变化, 不能把训练误差上升解释为模型退化. 此外, 验证地点所属国家名已在训练集中出现的样本数由 110 增至 128, 说明覆盖范围也在改变. 因而结果支持这两批**增广改善了固定配置的验证表现**.

2.2　6500 条训练数据下的最优特征层探索

实验目的与设置　上一节固定第 9 层比较数据量, 本节进一步检验扩大到 6500 条后, 第 9 层是否仍是较好的选择. 沿用相同的 6500 条训练数据和 130 条验证数据, 重新提取 Qwen3-4B-Base 全部 36 层的国名末词元特征, 层号从 0 开始, 最后一层取 final RMSNorm 之前的输出. 模型前向使用 bfloat16, 特征以 float16 保存, 本地回归使用 float64.

每层采用标准坐标平方损失和 Ridge, 偏置不正则化. 使用与 500 条全层探索相同的中心化/标准化候选, λ_2 粗网格及局部细化规则, 每个坐标的目标仍为式 (1), 预处理统计量只由训练集计算. 共比较 1577 个配置, 按验证集原始坐标 MSE 最小选择配置和层次, 地理 RMSE 作为补充指标. 大样本求解采用 2560×2560 的特征协方差矩阵, 每层和预处理只做一次特征分解, 复用于不同正则系数.

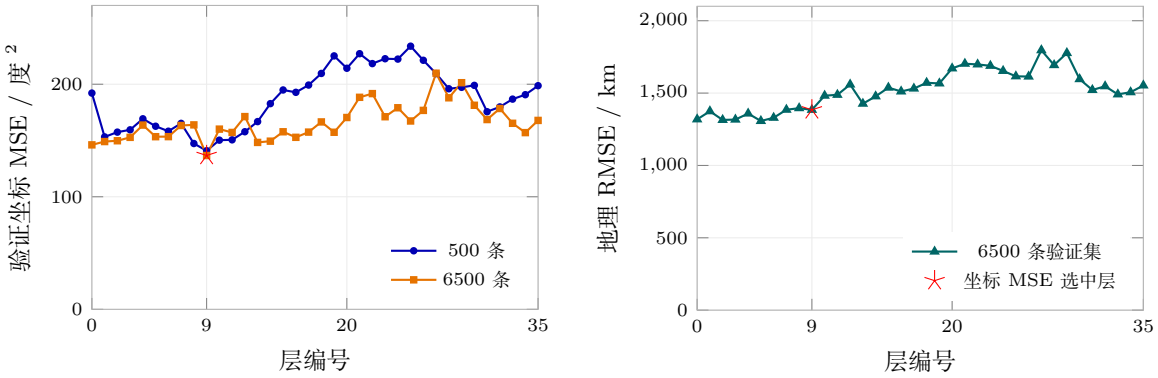


图 12: 两种训练规模的全层验证坐标 MSE, 以及 6500 条的地理 RMSE. 各点均使用该层按坐标 MSE 选出的配置; 右图没有按地理 RMSE 重新调参. 红星表示第 9 层.

表 12: 6500 条全层搜索的前三名, 以及第 11, 23, 35 层. 所列配置均为中心化; 坐标 MSE 单位为 deg^2.

层编号	λ_2	训练 MSE	验证 MSE	地理 RMSE / km
9	0.02279507	202.843	**136.680**	1384.276
0	0.0007598357	223.073	146.122	1318.510
13	0.03	197.826	148.293	1426.656
11	0.05773503	220.311	157.158	1488.151
23	0.01732051	168.666	171.110	1688.505
35	1.316074	191.768	167.841	1552.804

结果与分析 在本次 36 层及已评估的配置中, 第 9 层仍取得最低的验证坐标 MSE. 其最优配置为中心化, $\lambda_2 = 0.0227951$, 验证 MSE 为 $136.680\,\mathrm{deg}^2$, 地理 RMSE 为 1384.276 km, 平均距离为 936.610 km, 1000 km 内比例为 67.69%. 相比坐标 MSE 排名第二的第 0 层, 误差小 $9.443\,\mathrm{deg}^2$. 500 条和 6500 条调参后的最优层均为第 9 层, 但最优 λ_2 从 0.2279507 变为 0.0227951, 验证坐标 MSE 从 140.907 降至 136.680, 下降约 3.00%.

因此实验得出**标准坐标平方损失和当前搜索范围内, 第 9 层按验证坐标 MSE 最优**, 验证集同时用于调参和选层, 不是独立测试成绩.

下一节继续在第 9 层比较 A/B/C 三种损失函数, 沿用各组共同的标准化输入和固定 $\lambda_{\mathrm{reg}} = 0.01$.

2.3 数据增广后的地理损失消融

实验设计 将原始 500 条训练数据与两次各 3000 条增广数据合并为 6500 条, 验证集始终保持原有 `valid.csv` 的 130 条. 三个模型共用同一批特征, 用训练集均值和标准差标准化输入. 记 $z \in \mathbb{R}^{2560}$ 为经过训练集均值和标准差标准化后的第 9 层隐藏状态, 模型输出两个线性预测

$$\widehat{y} = \begin{bmatrix} \widehat{\phi} \\ \widehat{\lambda} \end{bmatrix} = Wz + b,$$

分别表示预测的纬度和经度. 本节训练坐标及三角函数输入均采用弧度, σ_ϕ 和 σ_λ 也以弧度计算; 表中的坐标 MSE 换回度后计算. 目标函数统一写作

$$J_k = \frac{1}{N}\sum_{i=1}^{N} L_k(y_i, \widehat{y}_i) + \lambda_{\mathrm{reg}}\|W\|_F^2, \quad \lambda_{\mathrm{reg}} = 0.01,$$

偏置不正则化. 设 $\Delta\phi = \widehat{\phi} - \phi$, $\Delta\lambda = \widehat{\lambda} - \lambda$, 比较

$$
\begin{aligned}
L_A &= (\Delta\phi)^2 + (\Delta\lambda)^2, \\
L_B &= \frac{(\Delta\phi)^2}{\sigma_\phi^2} + \frac{(\Delta\lambda)^2}{\sigma_\lambda^2}, \\
L_C &= 1 - \cos\gamma = 1 - \left[\sin\widehat{\phi}\sin\phi + \cos\widehat{\phi}\cos\phi\cos(\Delta\lambda)\right].
\end{aligned}
$$

其中 γ 为球心角; $\sigma_\phi = 0.512746$, $\sigma_\lambda = 1.305082$ 均只由 6500 条训练标签计算. 记

$$u(\phi, \lambda) = (\cos\phi\cos\lambda, \cos\phi\sin\lambda, \sin\phi),$$

球面项也可写成

$$L_C = \tfrac{1}{2}\|u(\widehat{\phi}, \widehat{\lambda}) - u(\phi, \lambda)\|_2^2.$$

A, B 使用 Ridge 解析解; C 使用 L-BFGS 优化算法, 分别从 A, B 及带固定扰动的 A 初始化, 仅按最小正则化训练目标选择结果. 三次在 573, 570, 577 次迭代后达到最大梯度绝对值小于 10^{-7}, 训练目标均约为 0.013828664; 选中从 B 初始化的结果. 三个初值收敛到相近目标不等于证明全局最优.

统一评估与结果 三组模型均采用前文定义的地理 RMSE 和原始坐标 MSE 进行评估.

表 13: 6500 条训练数据, 固定第 9 层和 $\lambda_{\text{reg}} = 0.01$ 的验证结果. 所有数值来自同一 130 条验证样本.

指标	A: 标准 MSE	B: 标准化 MSE	C: 球面损失
地理 RMSE / km	1734.716	1650.832	**1037.855**
平均距离 / km	1225.655	1183.636	**844.647**
中位距离 / km	958.749	863.931	**686.562**
P90 距离 / km	2498.823	2246.981	**1632.421**
原始坐标 MSE / deg^2	180.335	166.615	**164.585**
1000 km 内比例	52.31%	56.92%	**68.46%**

C 的地理 RMSE 较 A 降低 40.17%, 较 B 降低 37.13%; 130 个地点中有 82 个优于 A, 85 个优于 B, 并非每个地点都改善. 以验证地点 Mount Tomanivi 为例, 真实经度为 178.015°, A, B 预测约为 82°, C 为 179.397°, 距离误差从约 10000 km 降至 201.29 km. 球面损失模型在该样本上显著减小了经度偏差和地理距离误差. 但 C 仍有 41 个地点误差超过 1000 km, 不能视为精确定位.

结论与适用范围 结果支持在本数据, 固定层数与正则系数下, **球面损失比两种坐标 MSE 获得更小的验证地理误差**. 由于三种损失函数的数值尺度不同, 相同的正则化系数并不意味着相同的正则化强度. 因此, 本实验仅比较固定 $\lambda_{\text{reg}} = 0.01$ 时的表现, 不代表各损失函数分别调参后的最优性能. 第 9 层的前期选择及 6500 条下的复核分别见第 2.1, 2.2 节.

2.4 真假预测的全层特征比较

在思考题 1.9 的三层比较基础上, 使用同一组 5088 条训练数据和 300 条验证数据, 进一步探索 Qwen3-4B-Base 的全部 36 层. 重新提取句子最后一个实际词元的 2560 维特征, 层编号为 0–35, 均取最终 RMSNorm 之前的对应解码块输出. 冻结语言模型, 每层沿用思考题 1.9 的两种预处理与 12 个正则化配置, 共训练 $36 \times 2 \times 12 = 864$ 个逻辑回归候选. 预处理统计量仅由训练集计算, 分类阈值固定为 0.5. 共有 742 个候选在 3000 次迭代内达到 10^{-5} 的 KKT 残差标准; 其中 701 个已收敛的正则化候选参与选优, 仍按验证准确率优先, 同分时比较 BCE.

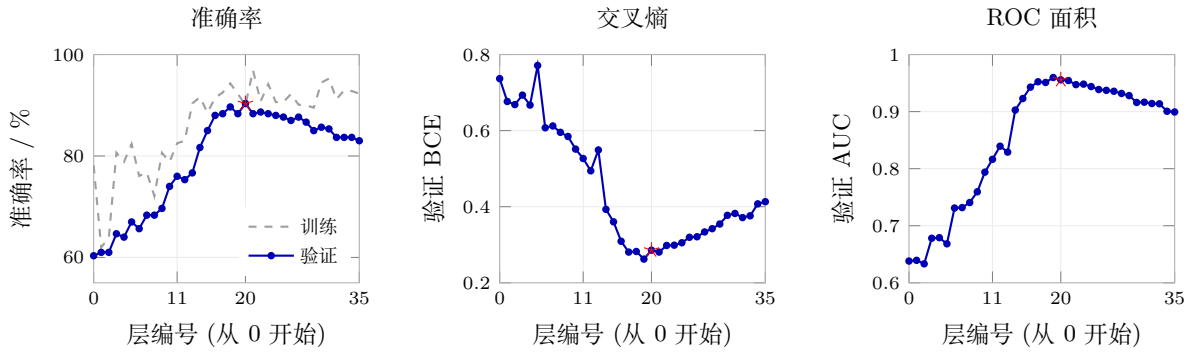


图 13: 真假预测的全层比较. 每层均按相同规则选取配置, 蓝线为验证指标, 左图灰线为训练准确率. 红星统一标记按验证准确率选出的第 20 层.

表 14: 全层实验的代表层结果. 各行均为该层按准确率选出的配置.

层	预处理	λ_1	λ_2	验证准确率	验证 BCE	验证 AUC
11	中心化	0	0.01	76.00%	0.52667	0.81636
18	标准化	0.001	0.01	89.67%	0.28230	0.95107
19	标准化	0	0.1	88.33%	0.26227	0.95973
20	中心化	0	0.1	**90.33%**	0.28580	0.95564
23	中心化	0.001	0.01	88.33%	0.29886	0.94818
35	标准化	0.001	0.01	83.00%	0.41315	0.89933

第 20 层采用中心化和纯 ℓ_2 正则化 ($\lambda_2 = 0.1$), 训练准确率为 90.06%, 验证准确率为 **90.33%** (271/300), F1 为 0.90615. 相比同一轮特征提取与搜索中的第 23 层 88.33%, 提升 2.00 个百分点, 净多判对 6 条; 相比第 18 层仅净多判对 2 条.

曲线显示中间层整体更适合本任务的线性分类, 最深层并非最好. 第 19 层所选模型的 BCE 和 AUC 均优于第 20 层, 说明准确率最优不等于各项指标同时最优. 每层分别调参, 因此这里比较的是各层在既定搜索范围内的最好候选; 验证集又被用于选择层数, 不能据此断言第 20 层具有稳定或显著优势, 仍需独立测试确认.

参考文献

[1] Quinlan, R. (1993). Auto MPG. UCI Machine Learning Repository. https://doi.org/10.24432/C5859H

[2] scikit-learn. ElasticNet API. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.ElasticNet.html

[3] scikit-learn. Ridge API: objective function and regularization parameters. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html

[4] scikit-learn. Lasso API: objective function and regularization parameters. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html

[5] scikit-learn. Linear Models: Logistic Regression. https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

[6] Natural Earth. 1:110m Coastline, public-domain coastline data. https://www.naturalearthdata.com/downloads/110m-physical-vectors/110m-coastline/

[7] Gurnee, W. and Tegmark, M. (2024). Language Models Represent Space and Time. arXiv:2310.02207. https://arxiv.org/abs/2310.02207