算法基础：习题解答 1

问题 1（15 分）

(1) 由于所有的球都是等概率投放到盒子中的，因此每一种投放方案的概率相等。共有 n 个球和 n 个盒子，总情况数为 n^n。

若第一个盒子中刚好有三个球，则先从 n 个球中选择三个球放入 1 号盒子，有 $\binom{n}{3}$ 种选择。剩余的 $n-3$ 个球只能放入其他 $n-1$ 个盒子，有 $(n-1)^{n-3}$ 种情况。因此，准确概率为

$$P = \frac{\binom{n}{3}(n-1)^{n-3}}{n^n} = \frac{(n-1)(n-2)}{6n^2}\left(1-\frac{1}{n}\right)^{n-3}. \tag{1}$$

当 n 很大时，近似化简为

$$P \approx \frac{1}{6e}. \tag{2}$$

(2) 设指示变量 $I_i = 1$ 表示第 i 个盒子有刚好三个球，$I_i = 0$ 表示第 i 个盒子没有刚好三个球。刚好有三个球的盒子数量为 $I = \sum_{i=1}^{n} I_i$。由期望的线性性，

$$\mathbb{E}[I] = \sum_{i=1}^{n} \mathbb{E}[I_i] = n\mathbb{P}(I_i = 1) = \frac{(n-1)(n-2)}{6n}\left(1-\frac{1}{n}\right)^{n-3} \approx \frac{n}{6e}. \tag{3}$$

(3) 与上一问使用相同的方法。设 I_i 表示随机排列中第 i 个位置是否为不动点，则

$$\mathbb{E}[I] = \sum_{i=1}^{n} \mathbb{E}[I_i] = n\mathbb{P}(I_i = 1) = n\frac{(n-1)!}{n!} = 1. \tag{4}$$

(4) 每次投掷骰子，第一面向上的概率为 $1/\ell$。若第一面向上，则再继续投掷；否则结束。于是期望投掷次数满足

$$E = 1 + \frac{1}{\ell}E, \qquad E = \frac{\ell}{\ell-1} \quad (\ell > 1).$$

问题 2（30 分）

(1) 所有专家权重 $c_i^{(t)}$ 的具体大小并不重要，只需考虑其相对大小即可。因此，对所有 i 同时将权重乘以同一正数，不会影响加权多数投票（majority voting）的结果。

原算法中，正确的专家权重乘 2，错误的专家权重除以 2。将每一轮更新后的权重同时除以 2，就等价于：正确的专家权重不变，错误的专家权重除以 4。

设有 n 个专家、T 个轮次，每个专家初始权重为 1。记第 t 轮开始时权重总和为 W_t，最优专家为 a_1；它在前 t 轮的错误次数为 $s_1^{(t)}$，算法在前 t 轮的错误次数为 $m^{(t)}$。则

$$W_1 = n, \qquad W_{t+1} \geq w_{t+1}(a_1) = \left(\frac{1}{4}\right)^{s_1^{(t)}}.$$

下面证明：对算法选择错误的任意轮次 t，都有

$$W_{t+1} \leq \frac{5}{8}W_t. \tag{5}$$

证明. 在这一轮，若算法选择错误，那么支持算法所选答案的专家权重总和至少为 $W_t/2$。这些专家都发生了错误，其权重都要除以 4。因此总权重至少减少

$$\frac{W_t}{2} \cdot \frac{3}{4} = \frac{3W_t}{8},$$

从而 $W_{t+1} \le W_t - 3W_t/8 = 5W_t/8$。 □

正确轮次总权重不增加，所以

$$W_{t+1} \le \left(\frac{5}{8}\right)^{m^{(t)}} W_1 = n\left(\frac{5}{8}\right)^{m^{(t)}}. \tag{6}$$

结合最优专家的权重，得到

$$\left(\frac{1}{4}\right)^{s_1^{(t)}} \le n\left(\frac{5}{8}\right)^{m^{(t)}}. \tag{7}$$

对两边取对数，可得两个代价之间的关系：

$$m^{(t)} \le \frac{s_1^{(t)}\log 4 + \log n}{\log(8/5)}.$$

这里 n 是专家的数量。

(2) 将错误专家的权重更新系数改为 $1-2\epsilon$，其中 $0 < \epsilon < 1/2$。在算法错误的一轮，至少一半权重乘以 $1-2\epsilon$，所以总权重至多乘以 $1-\epsilon$。同样可得

$$(1-2\epsilon)^{\mathrm{cost}^*} \le n(1-\epsilon)^{\mathrm{cost}}. \tag{8}$$

于是

$$m^{(t)} \le \frac{s_1^{(t)}\log(1-2\epsilon) - \log n}{\log(1-\epsilon)}.$$

最优专家代价前的系数为

$$\frac{\log(1-2\epsilon)}{\log(1-\epsilon)} > 2,$$

且该系数可以任意趋近于 2。

先证明它一定大于 2。由于 $\log(1-\epsilon) < 0$，上述不等式等价于

$$1 - 2\epsilon < (1-\epsilon)^2,$$

移项后等价于 $\epsilon^2 > 0$，因此成立。

再证明它可以趋近于 2。由洛必达法则，

$$\lim_{\epsilon\to 0^+} \frac{\log(1-2\epsilon)}{\log(1-\epsilon)} = \lim_{\epsilon\to 0^+} \frac{-2/(1-2\epsilon)}{-1/(1-\epsilon)} = \lim_{\epsilon\to 0^+} \frac{2(1-\epsilon)}{1-2\epsilon} = 2.$$

当 $\epsilon = 1/4$ 时，该系数约为 2.41。由连续性和介值定理，它可以取遍 $(2, 2.41]$ 中的值。

Remark.

还可以给出更精确的取值，不使用介值定理。对于任意 $0 < \alpha < 1$，取 $\epsilon = \alpha/4$，则

$$f(\alpha) = \frac{\log(1-2\alpha/4)}{\log(1-\alpha/4)} = \frac{\log(1-\alpha/2)}{\log(1-\alpha/4)}.$$

定义

$$g(\alpha) = (2+\alpha)\log\left(1-\frac{\alpha}{4}\right) - \log\left(1-\frac{\alpha}{2}\right).$$

若 $g(\alpha) < 0$，则由于分母为负，有

$$\frac{\log(1-2\epsilon)}{\log(1-\epsilon)} < 2+\alpha.$$

注意 $g(0)=0$，且

$$g'(\alpha)=\log\left(1-\frac{\alpha}{4}\right)+\frac{\alpha(\alpha-1)}{(4-\alpha)(2-\alpha)}.$$

当 $\alpha\in(0,1)$ 时，两项均严格为负，故 $g'(\alpha)<0$。因此 g 严格单调递减，$g(\alpha)<g(0)=0$。这就找到一个 ϵ 使上述系数小于 $2+\alpha$。

(3) 令最优专家为 1 号，构造如下实例：每次的正确选项都是 1，错误选项都是 2；每一轮 1 号专家都选择正确选项 1，其他专家都选择同一个错误选项 2。

这样，1 号专家的 $s_1^{(T)}=0$，其他专家的 $s_i^{(T)}=T$。在开始的各轮，选择 2 的专家权重之和大于选择 1 的专家权重，算法便选择 2，并发生一次错误。错误后，2 至 n 号专家的权重都乘以 $1-2\epsilon$。直到

$$(n-1)(1-2\epsilon)^{m^{(t)}}<1 \tag{9}$$

时，算法才停止选择其他专家的答案，转而选择 1，之后一直回答正确。

因此，在权重相等时仍选择 2 的规则下，错误次数为

$$M=\left\lfloor\frac{\log(n-1)}{-\log(1-2\epsilon)}\right\rfloor+1=\Theta(\log n) \tag{10}$$

（固定 ϵ）。其他平局规则至多改变一次错误。这说明加性 $\log n$ 项是必需的。

(4) 对任意偶数时间长度 T，都能构造如下实例。规定：选择 1 和选择 0 的专家权重总和相等时，算法选择 0。取 $n=100$ 个专家，前 50 个专家在奇数轮回答 1，在偶数轮回答 0；后 50 个专家与他们相反。标准答案始终为 1。

第 1 轮，选择 1 和 0 的专家一样多，权重也一样，算法选择 0，发生错误。第 2 轮，选择 1 的专家恰是第一轮犯错的专家，其权重已经减小；算法仍选择 0，再次错误。

下面用归纳法证明算法每轮都选择 0。第 $2t-1$ 轮开始时，两组权重相同，因此算法选择 0 并发生错误。第 $2t$ 轮，选择 1 的专家是第 $2t-1$ 轮犯错的专家，其权重乘了 $1-2\epsilon$，因此其权重总和较小，算法仍选择 0 并发生错误。此轮结束时另一组错误专家也乘以 $1-2\epsilon$，这 100 个专家的权重重新相等。由归纳原理，算法始终选择 0。

于是

$$\min_i s_i^{(T)}=\frac{T}{2},\qquad m^{(T)}=T,$$

证明了乘性系数 2 的必要性。

问题 3（25 分）

(1) 外层循环为

$$\textbf{for } i=2 \textbf{ to } n,$$

执行次数为 $n-1=O(n)$。内层循环为

$$\textbf{for } j=2 \textbf{ to } \lfloor\sqrt{i}\rfloor.$$

对每个固定的 i，迭代次数约为 $\sqrt{i}-1=O(\sqrt{i})$。每次迭代执行一次模运算和一次条件判断，在单位成本模型下均为 $O(1)$。总时间复杂度为

$$T(n)=\sum_{i=2}^{n}O(\sqrt{i})=O\left(\sum_{i=1}^{n}\sqrt{i}\right).$$

用积分估计，

$$\sum_{i=1}^{n}\sqrt{i}\sim\int_1^n\sqrt{x}\,dx=\frac{2}{3}x^{3/2}\Big|_1^n=\frac{2}{3}n^{3/2}-\frac{2}{3}=O(n^{3/2}).$$

(2) 欧几里得算法的时间复杂度满足

$$f(a,b) = f(b, a \bmod b) + O(1). \tag{11}$$

设 $a \geq b > 0$。若 $b \leq a/2$，则最大参数在一步后至少减半；若 $b > a/2$，则 $a \bmod b = a - b < a/2$，再经过一步后最大参数至少减半。因此，每至多两次迭代，最大参数就减半。迭代次数为

$$O(\log a + \log b).$$

(3) 设 a, b 的二进制位数分别为 n, m，则

$$n = \lfloor \log_2 a \rfloor + 1, \qquad m = \lfloor \log_2 b \rfloor + 1.$$

在多字整数运算中，$a \bmod b$ 可通过长整数除法实现。每次减去 b 的一个移位倍数需要 $O(m+n)$ 次位运算，而列竖式最多需要 $O(m+n)$ 次这样的操作。因此，取模操作的时间复杂度为

$$O(m+n) \cdot O(m+n) = O((m+n)^2) = O((\log a + \log b)^2).$$

这适用于多字整数的位运算模型；在固定字长的 64 位机器上，单个机器字内的取模可视为常数时间。

对算法（b），计入多字整数取模时间后，递推式为

$$f(a,b) = f(b, a \bmod b) + O((\log a + \log b)^2). \tag{12}$$

上一问已知操作次数为 $O(\log a + \log b)$，因此将每次取模时间用初始位数的上界估计，总时间复杂度为

$$O((\log a + \log b)^3).$$

问题 4（30 分）

(1) 在 h_2-sort 之后、h_1-sort 之前，将数组 A 按下标模 h_1 划分为若干同余类。考虑元素 $A[i]$ 和 $A[i+h_2]$，记包含它们的同余类分别为 M, N。希望证明：h_1-sort 之后，仍有

$$A[i] \leq A[i+h_2].$$

使用从 0 开始的下标，设 $A[i]$ 在 M 中下标为 x，$A[i+h_2]$ 在 N 中下标为 y。因为 $i + h_2 > i$，

$$\left\lfloor \frac{i+h_2}{h_1} \right\rfloor \geq \left\lfloor \frac{i}{h_1} \right\rfloor, \qquad y \geq x.$$

设 M 的第一个元素为 $A[t]$，其中 $t = i \bmod h_1$。在原数组中往后数 h_2 个位置得到 $A[t+h_2]$，它属于 N。设其在 N 中下标为 k，从该位置开始截取连续子列

$$N^* = \{N[k], N[k+1], N[k+2], \ldots\}, \qquad N^*[j] = N[j+k].$$

它与 M 的一个前缀 M^* 等长，且每对对应元素在 A 中相差 h_2 个位置。因为已经做过 h_2-sort，所以排序前

$$N^*[j] \geq M^*[j], \qquad \forall j.$$

对两个等长序列分别排序后，上述逐秩不等式仍然成立。证明如下：若排序后的第 j 个 N^* 元素小于第 j 个 M^* 元素，那么至少 $j+1$ 个 N^* 元素小于该 M^* 元素。它们各自对应的 M^* 元素都不大于它们，因此至少 $j+1$ 个 M^* 元素严格小于其第 j 个元素，与排序后的秩矛盾。

记排序后的各序列为 $M^{\uparrow}, N^{\uparrow}, (M^*)^{\uparrow}, (N^*)^{\uparrow}$。向 M^* 加入其余元素只会使第 x 个次序统计量减小；向 N^* 加入前面的 k 个元素时，N 中第 $x+k$ 个元素不小于 N^* 中第 x 个元素。因此

$$M^{\uparrow}[x] \leq (M^*)^{\uparrow}[x] \leq (N^*)^{\uparrow}[x] \leq N^{\uparrow}[x+k].$$

由于 $N^*[0]$ 对应于 $M[0]$ 往后 h_2 的位置，$N^*[x]$ 对应于 $M[x]$ 往后 h_2 的位置，即原来的 $A[i+h_2]$，所以它在 N^* 中下标为 x，在 N 中下标为 $y=x+k$。因此，h_1-sort 之后

$$A[i+h_2]=N^{\uparrow}[y]=N^{\uparrow}[x+k]\geq M^{\uparrow}[x]=A[i]. \qquad \square$$

（2） 引入西尔维斯特（Sylvester）定理：对于任意互质的正整数 a,b，以及任意整数 $n>ab-a-b$，方程

$$ax+by=n$$

有非负整数解。

定理证明.

由于 a,b 互质，根据裴蜀定理存在整数 u,v 使 $au+bv=1$。因此，对任意整数 n，存在整数解 (x_0,y_0) 使 $ax_0+by_0=n$。所有整数解可表示为

$$(x,y)=(x_0+kb,y_0-ka), \qquad k\in\mathbb{Z}.$$

非负条件等价于

$$x_0+kb\geq 0, \quad y_0-ka\geq 0, \qquad -\frac{x_0}{b}\leq k\leq \frac{y_0}{a}.$$

选择 k 使 $0\leq x=x_0+kb\leq b-1$。此时

$$y=\frac{n-ax}{b}>\frac{ab-a-b-a(b-1)}{b}=-1.$$

因为 y 是整数，所以 $y\geq 0$。故存在非负整数解。 $\square$

回到原题.

假设已经分别做过 h_t-sort 和 h_{t+1}-sort，且 h_t,h_{t+1} 互质。由上一问，后续排序保持之前的有序性。只要

$$j-i\geq h_th_{t+1},$$

就可利用 Sylvester 定理找到非负整数 x,y，使

$$h_tx+h_{t+1}y=j-i.$$

于是

$$a_i\leq a_{i+h_tx}\leq a_{i+h_tx+h_{t+1}y}=a_j.$$

因此，下标距离至少 h_th_{t+1} 的元素对均已按顺序排列。

在 h_{t-1} 排序中，每次移动跨越 h_{t-1} 个位置。因此，每个数向前移动至多约 h_th_{t+1}/h_{t-1} 次，就会进入确保前面更远元素都不大于它的区间，此后不会再前移。它后面的数中，至多约 h_th_{t+1}/h_{t-1} 个数会使它向后移动。因此每个数的移动次数上界可以写为

$$2\left\lceil\frac{h_th_{t+1}}{h_{t-1}}\right\rceil.$$

对所有 n 个数求和，总移动次数至多

$$2n\left\lceil\frac{h_th_{t+1}}{h_{t-1}}\right\rceil=O\left(n\left(1+\frac{h_th_{t+1}}{h_{t-1}}\right)\right).$$

忽略整数取整时，所用的上界为 $2nh_th_{t+1}/h_{t-1}$，完成证明。 $\square$